GUÍA TÉCNICA Y MARCO CONCEPTUAL PARA TFG

Fundamentos de Bolsa, Indicadores Técnicos y Machine Learning Financiero

Manual de referencia sobre microestructura de mercado, corrientes de inversión, ingeniería de características (features) y diseño de clasificadores bursátiles.

1. Introducción e Historia: De las Velas Japonesas a la IA

Para diseñar una red neuronal capaz de asistir en decisiones de inversión, primero es necesario comprender qué es exactamente el mercado bursátil. Una bolsa de valores (como la Bolsa de Nueva York o el mercado de futuros de materias primas) no es más que un **libro de órdenes continuo** donde compradores (demanda) y vendedores (oferta) acuerdan precios para intercambiar activos. El precio que vemos en una pantalla en un segundo determinado es simplemente el precio al que se acaba de cruzar la última transacción entre un comprador y un vendedor.

Históricamente, el intento de predecir hacia dónde irán esos precios ha pasado por cuatro grandes etapas evolutivas que hoy convergen en vuestro proyecto:

- **Siglo XVIII (El nacimiento de las Velas Japonesas):** Munehisa Homma, un comerciante de arroz de Sakata (Japón), descubrió que aunque el precio del arroz dependía de las cosechas (oferta y demanda física), las emociones humanas de miedo y codicia creaban patrones repetitivos. Diseñó los gráficos de velas (*Candlesticks*) que seguimos usando hoy en día para resumir qué ocurre en cada sesión.
- **Finales del Siglo XIX y Siglo XX (Teoría de Dow y Análisis Técnico Clásico):** Charles Dow (cofundador del índice Dow Jones y del *Wall Street Journal*) postuló que el mercado se mueve en tendencias (primarias, secundarias y menores) y que el volumen debe confirmar la tendencia. En los años 70, ingenieros como J. Welles Wilder formularon indicadores matemáticos como el **RSI** o el **ATR** para medir la fuerza de esas tendencias con calculadoras mecánicas.
- **Años 1970–1990 (La Hipótesis del Mercado Eficiente vs. Finanzas Cuantitativas):** Economistas como Eugene Fama propusieron la *Hipótesis del Mercado Eficiente (EMH)*, afirmando que los precios ya reflejan toda la información disponible y siguen un "paseo aleatorio" (*Random Walk*) imposible de batir. Sin embargo, matemáticos como Jim Simons (fundador de Renaissance Technologies) demostraron empíricamente que existen ineficiencias estadísticas y patrones no lineales que los algoritmos pueden explotar.
- **Siglo XXI (Trading Algorítmico, Machine Learning y XAI):** Hoy en día, los modelos como el Perceptrón Multicapa (MLP) o las redes recurrentes (LSTM) no miran un único indicador aislado, sino que combinan docenas de métricas técnicas simultáneamente. El reto actual —tal y como aborda el sistema **DI2XAI**— ya no es solo que la red acierte, sino aplicar **Inteligencia Artificial Explicable (XAI)** mediante valores SHAP para que el inversor humano entienda *por qué* la máquina recomienda comprar.

2. Activos Financieros y Anatomía del Dataset (OHLCV)

En los mercados financieros existen distintas clases de activos. Para entrenar vuestros primeros modelos habéis barajado dos candidatos ideales por su liquidez y comportamiento:

- **Índices Bursátiles (ej. S&P 500 — Ticker: `^GSPC`):** Un índice no es una empresa individual, sino una cesta ponderada de las 500 mayores empresas cotizadas de EE. UU. (Apple, Microsoft, Nvidia, etc.). Su gran ventaja para el *Machine Learning* es que tiene un **sesgo estructural alcista a largo plazo** (crece conforme crece la economía mundial), pero sufre correcciones rápidas y volátiles cuando hay crisis, lo que ofrece excelentes puntos de entrada.
- **Materias Primas o *Commodities* (ej. Futuros del Cobre — Ticker: `HG=F`):** A diferencia del oro (que actúa como activo refugio conservador), el cobre es conocido en economía como *"Dr. Copper"* porque se utiliza en construcción, redes eléctricas, vehículos eléctricos y semiconductores. Es un activo cíclico, altamente volátil, que presenta fuertes tendencias alcistas y bajistas sin el crecimiento infinito de un índice tecnológico.

Las 5 Columnas Base (Datos OHLCV)

Cuando descargáis un archivo CSV desde Yahoo Finance (`yfinance`), cada fila representa una sesión bursátil (un día laborable; un año bursátil tiene aproximadamente **252 sesiones**, ya que los fines de semana y festivos la bolsa cierra). Cada fila contiene cinco variables fundamentales conocidas como **OHLCV**:

Columna	Significado en Bolsa	Importancia para el Modelo de IA
Open (Apertura)	Primer precio cruzado al sonar la campana de inicio del día.	Recoge la reacción emocional a las noticias ocurridas durante la noche. En simuladores realistas (como DI2XAI), las órdenes se ejecutan al precio `Open` del día siguiente.
High (Máximo)	El precio más alto que alguien estuvo dispuesto a pagar ese día.	Marca el techo intradía donde los compradores perdieron fuerza y aparecieron los vendedores (resistencia intradía).
Low (Mínimo)	El precio más bajo al que cayó el activo durante la sesión.	Marca el suelo intradía donde el activo resultó tan barato que entraron compradores agresivos (soporte intradía).
Close (Cierre)	Último precio del día al cerrar el mercado (y `Adj Close` descontando dividendos).	Es el precio de consenso más importante; sobre él se calculan la mayoría de medias móviles e indicadores técnicos.
Volume (Volumen)	Número total de acciones o contratos negociados durante el día.	Es la "gasolina" del movimiento. Una subida de precio con volumen alto indica que los grandes fondos (institucionales) están comprando.

3. Corrientes de Análisis y Dinámica del Mercado

Para contextualizar vuestro TFG, debéis distinguir las tres grandes escuelas o corrientes de análisis en bolsa y cómo se mueve el dinero dentro del mercado:

- **Análisis Fundamental:** Estudia las cuentas financieras de una empresa (beneficios, deuda, ventas, dividendos) para calcular su "valor intrínseco". Es propio de inversiones a muy largo plazo (años).
- **Análisis Técnico:** Asume que toda la información fundamental y psicológica ya está reflejada en el gráfico de precios y volumen. Utiliza indicadores matemáticos para detectar tendencias y giros.
- **Análisis Cuantitativo y Algorítmico (Vuestro enfoque):** Utiliza estadística avanzada y modelos de aprendizaje automático (KNN, MLP, RNN) sobre datos históricos (*backtesting*) para encontrar probabilidades matemáticas favorables de ganancia frente a riesgo.

Regímenes de Mercado y Conceptos Operativos Clave

El mercado nunca se mueve en línea recta; alterna entre tres estados o **regímenes** que vuestro clasificador debe saber distinguir mediante los indicadores:

1. **Mercado Alcista (*Bull Market*):** Sucesión de máximos y mínimos cada vez más altos. Domina el optimismo y las estrategias de seguimiento de tendencia (como comparar Medias Móviles o *Buy and Hold*) funcionan de forma excelente.
2. **Mercado Bajista (*Bear Market*):** Sucesión de caídas prolongadas por pesimismo o recesión económica. Comprar sin filtro aquí genera pérdidas severas.
3. **Mercado Lateral (*Sideways / Rango*):** El precio rebota entre un suelo (**Soporte**: zona de precios donde históricamente entran compradores y frenan la caída) y un techo (**Resistencia**: zona donde entran vendedores y frenan la subida). Aquí brillan los osciladores como el RSI.

> **Por qué el Flujo de Dinero (Smart Money) importa:** Los mercados los mueven los inversores institucionales (bancos de inversión, fondos de pensiones, *hedge funds*). Como manejan miles de millones de dólares, no pueden comprar todas sus acciones en un solo día sin disparar el precio en su contra. Acumulan posiciones poco a poco dejando huella en el **Volumen** y en las sombras de las velas. Por eso incluir métricas de flujo de dinero (como el MFI o el Volumen Relativo) da una ventaja enorme a una red neuronal frente a mirar solo el precio.

4. El Problema de la Estacionariedad y el Diseño del Target

El error más frecuente al programar una primera red neuronal financiera es meter la columna `Close` directamente como entrada (X) y pedirle que prediga el `Close` de mañana (y). Esto falla por dos motivos matemáticos fundamentales:

- **Falta de Estacionariedad:** En el año 2010 el S&P 500 cotizaba alrededor de 1.100 puntos; en 2024 superó los 5.000 puntos. Si entrenas un KNN o un MLP con datos de 2010 a 2020 (donde los precios eran de 1.000 a 3.000) y lo evalúas en 2023 (precios de 4.500), los pesos neuronales o las distancias euclidianas del KNN estarán completamente fuera de escala. **Solución:** Todas las entradas (X) de vuestro modelo deben ser *porcentajes, ratios o escalas acotadas (0 a 100).*
- **De Regresión a Clasificación por Márgenes (Enfoque DI2XAI / Triple Barrera):** Al inversor no le sirve saber si mañana el precio subirá un 0.05% (lo cual se lo comen las comisiones del bróker). Lo útil es plantear una pregunta binaria o multiclase: *"Si compro hoy al precio actual, ¿superará el activo un margen de beneficio del +X% dentro de los próximos N días?"*. Así convertimos un problema ruidoso en un clasificador de oportunidades de alta probabilidad.

5. Diccionario Completo de Indicadores (Features para vuestro Clasificador)

A continuación se detallan todas las familias de medidores que calcula el script de Python adjunto, explicando su fórmula matemática, qué fenómeno bursátil miden exactamente y por qué aportan valor predictivo al clasificador.

5.1. Indicadores de Estructura e Histórico (Aportación clave del paper DI2XAI)

Estos tres indicadores fueron demostrados mediante análisis SHAP en el artículo de referencia como los más influyentes para que un Perceptrón Multicapa (MLP) tome decisiones ganadoras a medio y largo plazo:

- **Distancia actual al máximo histórico (`dif2max`):** Mide la caída porcentual (también llamada *Drawdown*) desde el precio más alto jamás alcanzado por el activo hasta el día actual t (sin mirar nunca datos posteriores al día t).
  Fórmula: $dif2max_t = (MáxHistórico_t - Precio_t) / MáxHistórico_t \times 100$.
  Qué mide: Si vale 0%, el activo está en máximos históricos (subida libre). Si vale 20%, el activo tiene un "descuento" del 20% respecto a su techo histórico.
- **Distancia media histórica al máximo (`dif2maxAvg`):** Es la media acumulada de todos los valores de `dif2max` desde el inicio de la serie hasta el día t .
  Qué mide: Actúa como un termómetro del **riesgo intrínseco o volatilidad histórica** del activo. Si una acción muy estable tiene un `dif2maxAvg` del 4%, pero hoy su `dif2max` es del 12%, la red neuronal detecta inmediatamente una oportunidad de compra excepcional por caída exagerada.
- **Rentabilidad suavizada a 3 años (`profitMa3years`):** Calcula el porcentaje de beneficio comparando la Media Móvil de 20 sesiones actual con la Media Móvil de 20 sesiones de hace exactamente 3 años (756 sesiones bursátiles).
  Fórmula: $profitMa3years_t = (MA20_t - MA20_{t-756}) / MA20_{t-756} \times 100$.
  Qué mide: Mide el crecimiento estructural de fondo eliminando el ruido puntual de un día concreto. Permite al modelo saber si está operando en un activo ganador a largo plazo.

5.2. Indicadores de Tendencia Relativa (Medias Móviles Normalizadas)

Una Media Móvil Simple (MA_n) es el promedio de los precios de cierre de los últimos n días. Suaviza la curva de precios para mostrar la dirección de la tendencia:

- **Distancia porcentual Precio a Medias Móviles (`dist_MA10` , `dist_MA20` , `dist_MA50` , `dist_MA100`):** En lugar de darle a la red el valor en dólares de la media (que no es estacionario), calculamos $(Precio_t - MA_n) / MA_n \times 100$. Mide si el precio está por encima de su tendencia (positivo) o por debajo (negativo) y cuán "estirado" está como una goma elástica.
- **Ratios de Cruce de Medias (`ratio_MA10_MA50` y `ratio_MA20_MA100`):** Cuando la media rápida (ej. 10 o 20 días) cruza por encima de la media lenta (ej. 50 o 100 días), en bolsa se denomina *Cruce Dorado (Golden Cross)* e indica el inicio de una tendencia alcista. El ratio $MA_{rápida} / MA_{lenta}$ le da este dato exacto a la red centrándolo en torno a 1.0.
- **Pendiente de la Media Móvil (`slope_MA50`):** Mide la tasa de cambio de la media de 50 días respecto a hace 5 sesiones. Indica si la tendencia de fondo se está empinando al alza, aplanándose o girándose a la baja.

5.3. Indicadores de Impulso y Agotamiento (Momentum)

Miden la velocidad a la que sube o baja el precio para detectar cuándo un movimiento está exhausto:

- **RSI (*Relative Strength Index* — 14 sesiones):** Oscilador acotado entre 0 y 100. Calcula la relación entre el promedio de subidas y el promedio de bajadas de los últimos 14 días: $RSI = 100 - [100 / (1 + RS)]$.
  Regla bursátil: Valores por encima de **70** indican *Sobrecompra* (el activo ha subido demasiado rápido y puede corregir); valores por debajo de **30–35** indican *Sobreventa* (pánico vendedor, alta probabilidad de rebote alcista).
- **MACD Normalizado y su Histograma (`macd_norm` , `macd_hist_norm`):** El MACD resta la media exponencial de 26 días a la de 12 días, y la compara con una línea de señal (media de 9 días del propio MACD). Dividido entre el precio, el histograma muestra la aceleración o frenada del impulso alcista/bajista antes de que se vea a simple vista en el precio.
- **Retornos Acumulados o ROC (`ret_1d` , `ret_5d` , `ret_20d`):** El porcentaje de variación en el último día, la última semana (5 sesiones) y el último mes (20 sesiones). Aporta memoria reciente directa a modelos no secuenciales como KNN y MLP.
- **Estocástico Rápido (`stoch_k`):** Mide de 0 a 100 dónde se sitúa el cierre de hoy dentro de la horquilla entre el máximo más alto y el mínimo más bajo de las últimas 14 sesiones.

5.4. Indicadores de Volatilidad, Flujo de Dinero y Microestructura

Indicador (Variable en Código)	Categoría	Qué mide exactamente y por qué ayuda a la Red Neuronal
NATR (`natr_14`) *Normalized Average True Range*	Volatilidad	Mide el rango real medio de movimiento diario en los últimos 14 días expresado como % del precio. Permite al modelo saber si el margen objetivo (ej. +5%) es fácil o difícil de alcanzar en el entorno actual.
Bandas de Bollinger (`bb_width` y `bb_pct_b`)	Volatilidad / Rango	Envuelven la MA20 sumando y restando 2 desviaciones típicas ($\pm 2\sigma$). `bb_width` mide la anchura del canal (compresión vs. explosión de volatilidad) y `bb_pct_b` indica si el precio toca la banda inferior (0) o superior (1).
MFI (`mfi_14`) *Money Flow Index*	Flujo de Dinero	Es el "RSI ponderado por Volumen" (de 0 a 100). Multiplica el precio típico diario por el volumen negociado. Detecta si está entrando dinero institucional real aunque el precio parezca quieto.
Volumen Relativo (`rvol_20`)	Flujo de Dinero	Cociente entre el volumen de hoy y la media de volumen de 20 sesiones. Un pico de volumen en un suelo de mercado suele marcar el final de una caída (capitulación).
Geometría de Vela (`candle_body`, `upper_wick`, `lower_wick`)	Microestructura	Descompone la vela diaria en cuerpo y mechas respecto al rango total ($High - Low$). Captura rechazos intradía sin necesidad de descargar datos por minutos.

6. Reglas de Oro Metodológicas para vuestro TFG

A la hora de defender vuestro trabajo ante el tribunal y analizar los resultados del código en Python, tened siempre presentes estos tres principios de ingeniería financiera:

1. **Prohibición absoluta de *Look-Ahead Bias* (Sesgo de Mirada al Futuro):** Ningún indicador del día t puede utilizar precios del día $t+1$ en adelante. Además, cuando escaléis las variables (con `StandardScaler` o `MinMaxScaler` para que el KNN y el MLP funcionen bien), el escalador debe ajustarse (`.fit()`) **únicamente con el conjunto de entrenamiento (Train)** y luego aplicarse (`.transform()`) al conjunto de prueba (Test).
2. **Partición Temporal Estricta (No Barajar):** En series temporales financieras, `shuffle=False` es obligatorio. Si entrenáis con el primer 80% de la historia (ej. 2010–2021) y evaluáis en el 20% final (2022–2025), simuláis de forma honesta cómo habría operado vuestra IA en el mundo real.
3. **Purga de la Cola de Datos:** Como para etiquetar si el día t fue una buena compra necesitamos mirar qué ocurrió en los N días siguientes (el horizonte de inversión), las últimas N filas del dataset descargado aún no tienen futuro conocido completo y deben eliminarse antes de entrenar.